LEEVIDA · SISTEMA DE PRONTUÁRIO CLÍNICO

Inteligência Artificial no LeeVida

Como a IA apoia a decisão clínica — e onde a decisão continua a ser do profissional de saúde.

Neste documento

1. Visão geral e princípios
2. Arquitectura
3. As seis funcionalidades de IA
4. Privacidade e protecção de dados
5. Fiabilidade e tolerância a falhas
6. Auditoria e rastreabilidade
7. Testes e validação
8. Limitações e trabalho futuro

Anexo — Configuração

1. Visão geral e princípios

O LeeVida integra inteligência artificial generativa (modelos **Google Gemini**) em seis pontos do percurso clínico: triagem, preparação da consulta, prescrição, verificação de receitas, interpretação de exames e codificação de diagnósticos. Em todos eles a IA **sugere**; quem decide é sempre o enfermeiro ou o médico.

A integração foi desenhada para um contexto clínico real, em que um erro pode prejudicar um paciente e em que o serviço de IA, por ser externo, pode ficar lento ou indisponível. Por isso assenta em cinco princípios:

Princípio	O que significa na prática
Apoio, não decisão	Toda a sugestão tem de ser confirmada por um profissional. A interface identifica claramente o que vem da IA e lembra que a responsabilidade é clínica.
Rede de segurança determinística	Regras locais (sinais vitais, alergias, valores de pânico laboratoriais) funcionam sem IA e sem rede. A IA pode tornar uma decisão *mais* cautelosa, nunca menos.
Privacidade por omissão	O modelo recebe apenas dados clínicos anonimizados: nunca o nome, o BI, o telefone ou a morada do paciente.
Degradação graciosa	Se a IA falhar, a aplicação continua a funcionar: a triagem usa só as regras, a verificação de receitas cruza só as alergias, e o profissional é avisado.
Rastreabilidade	Cada utilização da IA fica registada na auditoria, incluindo quando um médico assina uma receita apesar de um alerta.

2. Arquitectura

O browser nunca fala directamente com a IA. Todos os pedidos passam pela API do LeeVida, que verifica o perfil do utilizador, monta um contexto clínico anonimizado, aplica as regras de segurança e só então contacta o Gemini. A chave de acesso à API Gemini existe apenas no servidor.

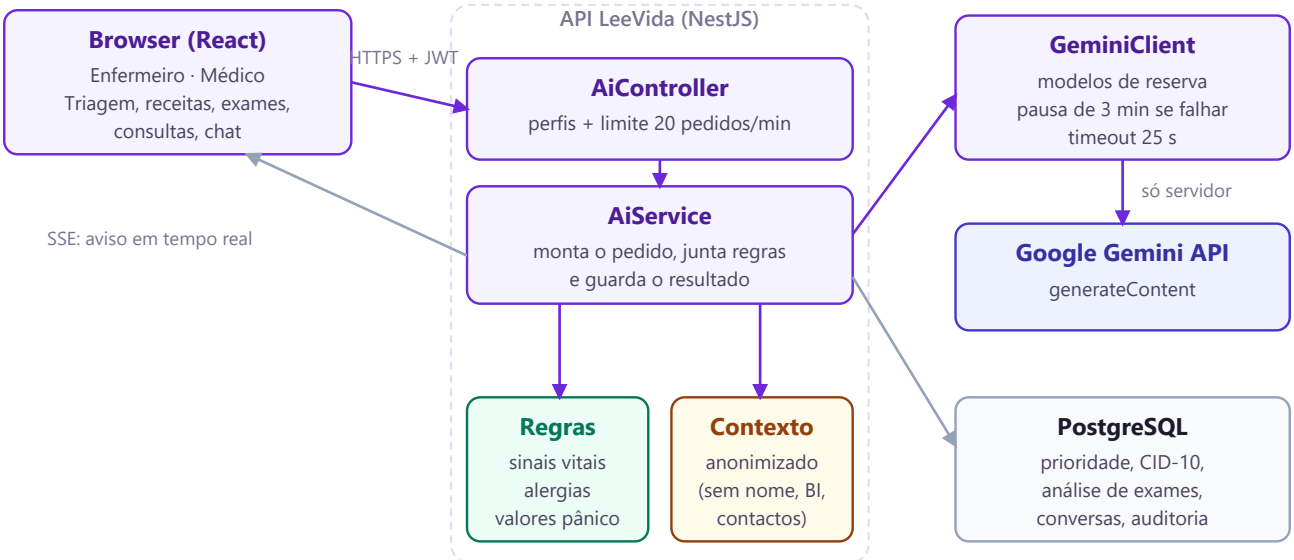


Figura 1 — Fluxo de um pedido de IA. A verde, as regras que funcionam sem IA; a laranja, a anonimização dos dados.

Componentes principais (backend)

Componente	Responsabilidade
`GeminiClient`	Comunicação com a API Gemini: cadeia de modelos de reserva, timeout por modelo, pausa automática de modelos sobrecarregados e saída JSON estruturada.
`clinical-context`	Constrói o resumo clínico anonimizado (idade, sexo, alergias, sinais vitais, diagnósticos, medicação, exames).
`clinical-rules`	Regras determinísticas: piso de prioridade por sinais vitais, conflitos de alergia por classe de fármaco e valores de pânico laboratoriais.
`AiService`	Implementa as seis funcionalidades, combina regras e IA, guarda resultados e regista a auditoria.
`AiController`	Expõe os endpoints `/api/v1/ai/*`, restringe cada um ao perfil certo e limita o uso a 20 pedidos por minuto por utilizador.

3. As seis funcionalidades de IA

Funcionalidade	Quem usa	Onde na aplicação	Salvaguarda principal
Triagem (Manchester)	Enfermeiro	Módulo de Triagem	Piso de prioridade pelos sinais vitais
Resumo pré-consulta	Médico	Ficha do paciente (automático)	Só dados do prontuário; aviso para confirmar
Assistente de prescrição	Médico	Botão flutuante; nova receita	Contexto anonimizado; decisão do médico
Verificação da receita	Médico	Ao assinar uma receita	Regras de alergia independentes da IA
Exames: valores críticos	Médico	Ao registar o resultado; página de Exames	Regras de valores de pânico, aviso imediato
Sugestão de CID-10	Médico	Ao concluir a consulta	Validação do formato; escolha manual

3.1 Triagem pela Escala de Manchester

Depois de registar os sinais vitais e os sintomas, o enfermeiro pode pedir uma sugestão de prioridade. A IA devolve a cor (Vermelho, Laranja, Amarelo, Verde ou Azul), uma justificação curta e os sinais de alarme encontrados. A cor fica pré-seleccionada, mas o enfermeiro confirma ou altera antes de gravar.

Como funciona a rede de segurança

Antes de consultar a IA, o sistema calcula uma **prioridade mínima** a partir dos sinais vitais. A prioridade final é sempre a mais urgente entre a da IA e a das regras: a IA pode subir a prioridade por causa dos sintomas (por exemplo, dor torácica), mas nunca a pode descer abaixo do que os sinais vitais impõem.

Prioridade mínima	Condições (qualquer uma)
Vermelho	SpO_2 < 85% · PA sistólica < 70 mmHg · FC < 40 ou > 150 bpm · temperatura ≥ 41 °C ou < 32 °C
Laranja	SpO_2 < 90% · PA sistólica < 90 mmHg · PA ≥ 200/120 mmHg · FC < 50 ou > 130 bpm · temperatura ≥ 40 °C ou < 35 °C
Amarelo	SpO_2 < 94% · PA ≥ 160/100 mmHg · FC > 110 bpm · temperatura ≥ 38,5 °C
Verde	Sinais vitais dentro destes limites — a classificação depende dos sintomas

Na fila de espera do médico, os doentes passam a estar ordenados por cor e depois por hora de chegada. Quando a prioridade é Vermelha ou Laranja, os médicos recebem uma notificação em tempo real marcada como atendimento prioritário. Fica gravado se a cor foi sugerida pela IA e confirmada, alterada pelo enfermeiro, ou definida apenas pelas regras.

> **Exemplo real (teste de 29/10/2026):** PA 150/95, FC 118, SpO_2 89%, "dor no peito em aperto há 40 minutos, irradia para o braço esquerdo, suores frios". As regras impuseram no mínimo **Laranja** (SpO_2 < 90%); a IA subiu para **Vermelho**, identificando suspeita de síndrome coronária aguda.

3.2 Resumo pré-consulta

Quando o médico abre a ficha de um paciente, é gerado automaticamente um resumo de cerca de 180 palavras, organizado em *pontos-chave*, *problemas activos*, *medicação e alergias* e *a vigiar nesta consulta*. O objectivo é que o médico se oriente em 30 segundos antes de chamar o doente.

- O resumo fica em cache no servidor durante até 6 horas e é invalidado automaticamente quando o prontuário muda (nova consulta, exame, receita ou alteração das alergias). Reabrir o mesmo paciente é instantâneo e não gasta pedidos à IA.
- A IA é instruída a usar apenas os dados fornecidos e a dizer explicitamente quando há poucos dados.
- Se a IA não estiver configurada, o cartão simplesmente não aparece.

3.3 Assistente de prescrição (chat)

Um assistente de conversação, disponível apenas para médicos, ajuda a escolher medicação, calcular doses, verificar interacções e redigir receitas. O médico pode colocar um paciente em contexto: nesse caso, o histórico clínico anonimizado é tido em conta em todas as respostas.

- As respostas indicam fármaco pela Denominação Comum Internacional, dose, via, frequência, duração e ajustes (idade, peso, função renal ou hepática, gravidez).
- Se existir alergia, contra-indicação ou interacção relevante, a resposta começa com um aviso explícito.
- O assistente considera o contexto epidemiológico angolano (malária, tuberculose, VIH, doenças diarreicas, anemia falciforme) e recusa pedidos não clínicos.
- As conversas ficam guardadas no servidor, associadas ao médico, com histórico e opção de nova conversa. Um médico não consegue ver as conversas de outro.
- No formulário de nova receita, o botão *Pedir sugestão à IA* abre o assistente com o paciente e a consulta já preenchidos.

3.4 Verificação da receita antes da assinatura

Ao assinar uma receita, o sistema faz uma verificação de segurança e mostra o resultado: **OK**, **Atenção** ou **Perigo**, com a lista de problemas encontrados (alergia, interacção, dose, contra-indicação ou duplicação).

- **Regras locais de alergia** cruzam as alergias registadas com os medicamentos, incluindo classes de fármacos (por exemplo, alergia a penicilina detecta amoxicilina, ampicilina, flucloxacilina…; alergia a aspirina detecta outros anti-inflamatórios não esteróides). Estas regras correm sempre, mesmo que a IA esteja em baixo.
- **A IA** acrescenta interacções, doses fora do intervalo habitual e contra-indicações pelo histórico.
- Com resultado **Perigo**, o médico tem de marcar explicitamente que reviu os alertas antes de poder assinar; essa decisão fica registada na auditoria.

> **Exemplo real:** receita de paracetamol 500 mg + ibuprofeno 400 mg para um paciente alérgico à aspirina. Resultado: **Perigo**, detectado em simultâneo pela regra local (ibuprofeno pertence à classe dos AINE) e pela IA (risco de reactividade cruzada).

3.5 Exames: valores críticos e interpretação

Quando o resultado de um exame é registado, acontecem duas coisas:

- **De imediato e sem IA**, regras de valores de pânico procuram no texto do resultado valores que exigem acção urgente. Se encontrarem algum, o exame é marcado como crítico e o médico que o pediu recebe logo uma notificação em tempo real.
- **Em segundo plano**, a IA analisa o resultado completo: identifica todos os parâmetros fora da referência (crítico, alto, baixo ou anormal) e escreve uma interpretação curta com hipóteses e próximos passos. Se a API estiver sobrecarregada, tenta de novo após 30 segundos, 2 minutos e 5 minutos.

Parâmetro	Valor de pânico (adulto)	Unidades reconhecidas
Hemoglobina	< 7 g/dL	g/dL e g/L
Plaquetas	< 20 000 ou > 1 000 000 /µL	/µL e $\times 10^3$/µL
Leucócitos	< 2 000 ou > 50 000 /µL	/µL e $\times 10^3$/µL
Potássio	< 2,8 ou > 6,2 mmol/L	mmol/L
Sódio	< 120 ou > 160 mmol/L	mmol/L
Glicemia	< 50 ou > 450 mg/dL	mg/dL e mmol/L
Cálcio	< 6,5 ou > 13 mg/dL	mg/dL e mmol/L

As regras prevalecem sobre a IA: se a IA classificar um resultado como não crítico mas uma regra detectar um valor de pânico, o exame continua marcado como crítico. Na página de Exames, o médico vê o marcador *Crítico* e pode abrir a interpretação completa. A enfermagem não vê nem os resultados nem a análise da IA.

3.6 Sugestão de códigos CID-10

Ao concluir a consulta, o médico pode pedir sugestões de códigos da Classificação Internacional de Doenças (CID-10) a partir do diagnóstico escrito. A IA devolve de um a quatro códigos com a designação e uma justificação; o médico escolhe quais gravar.

- Códigos com formato inválido são descartados no servidor (a CID-10 tem sempre uma letra e dois dígitos, por exemplo `B50.9`).
- Os códigos escolhidos ficam gravados na consulta e aparecem no detalhe da consulta, no prontuário e nas exportações.

> **Exemplo real:** "Malária grave por Plasmodium falciparum" → `B50.8` Outras formas graves e complicadas de malária por P. falciparum; `B50.0` com complicações cerebrais; `B50.9` não especificada.

4. Privacidade e protecção de dados

Os dados de saúde são dados pessoais sensíveis nos termos da Lei n.º 22/11 (Lei da Protecção de Dados Pessoais de Angola). Por isso, os pedidos à IA são construídos para enviar apenas o mínimo necessário para a recomendação clínica.

Enviado ao modelo	Nunca enviado
Idade, sexo e grupo sanguíneo	Nome do paciente
Alergias registadas	Número do BI
Últimos sinais vitais e sintomas	Telefone e email
Motivos, diagnósticos e códigos CID-10 das consultas recentes	Morada e contacto de emergência
Medicação prescrita recentemente	Dados do médico ou da clínica
Tipo e resultado dos exames recentes	Credenciais ou tokens de sessão

Esta separação é garantida por um teste automático, que verifica que o pedido enviado ao modelo contém as alergias do paciente mas não contém o nome, o BI, o telefone nem a morada.

- A chave da API Gemini existe apenas no servidor; o browser nunca a recebe.
- Cada endpoint de IA está restrito ao perfil adequado: a triagem à enfermagem, as restantes funcionalidades aos médicos.
- As conversas do assistente são privadas de cada médico.

> **Antes de usar com dados reais:** no plano gratuito da API Gemini, a Google pode utilizar o conteúdo dos pedidos para melhorar os seus produtos. Para dados de pacientes deve ser usado o **plano pago** (faturação activa no projecto Google Cloud), e o consentimento informado dos pacientes deve cobrir o uso de ferramentas de IA.

5. Fiabilidade e tolerância a falhas

A API Gemini é um serviço externo que pode ficar lento ou sobrecarregado — durante os testes deste projecto chegou a responder "high demand" em vários modelos em simultâneo. A integração foi construída para que isso não pare o trabalho clínico.

Mecanismo	Como funciona
Modelos de reserva	Os pedidos vão primeiro para `gemini-3.5-flash`; se falhar, seguem para `gemini-3.8-flash` e depois `gemini-3.5-flash-lite`. A lista é configurável.
Timeout por modelo	Cada modelo tem 25 segundos para responder; se não responder, passa-se ao seguinte em vez de deixar o utilizador à espera.
Pausa automática	Um modelo que falha (sobrecarga, limite ou timeout) fica em pausa durante 3 minutos e passa para o fim da fila; os pedidos seguintes vão directamente para um modelo saudável.
Repetição em segundo plano	A análise automática de exames tenta de novo após 30 s, 2 min e 5 min.
Saída estruturada	Triagem, verificação de receitas, exames e CID-10 pedem respostas em JSON com um esquema fixo, validado antes de ser usado.
Degradação graciosa	Sem IA: a triagem usa as regras de sinais vitais, a verificação de receitas cruza as alergias, os valores de pânico continuam a ser detectados e o assistente mostra uma mensagem clara.
Controlo de custos	Limite de 20 pedidos por minuto por utilizador, envio apenas das 20 últimas mensagens da conversa e cache do resumo pré-consulta.

6. Auditoria e rastreabilidade

Todas as utilizações da IA ficam registadas no log de auditoria do sistema, com o utilizador, a data e hora, o IP e o recurso afectado.

Acção registada	Quando acontece
`USOU_ASSISTENTE_IA`	Cada mensagem enviada ao assistente de prescrição
`IA_SUGERIU_PRIORIDADE`	Sugestão de cor de triagem
`IA_RESUMO_PRONTUARIO`	Geração de um resumo pré-consulta (não regista leituras em cache)
`IA_VERIFICOU_RECEITA_*`	Verificação de receita, com o resultado (OK, ATENCAO ou PERIGO)
`ASSINOU_RECEITA_COM_ALERTA_IA`	O médico assinou uma receita com alerta de Perigo
`ASSINOU_RECEITA_SEM_VERIFICACAO`	O médico assinou quando a verificação não foi possível
`IA_INTERPRETOU_EXAME`	Interpretação de exame pedida pelo médico
`IA_SUGERIU_CID10`	Sugestão de códigos CID-10

Para além da auditoria, os dados clínicos guardam a origem da decisão: a prioridade de triagem regista se foi sugerida pela IA e confirmada, alterada pelo enfermeiro, definida por regras ou escolhida manualmente; os parâmetros de exame indicam se foram assinalados por regra ou pela IA.

7. Testes e validação

O backend tem 96 testes automáticos, dos quais cerca de 40 cobrem a IA e as regras clínicas. Os testes não chamam a API real: simulam as respostas do Gemini para verificar o comportamento do sistema em cada cenário.

- **Privacidade:** o contexto enviado ao modelo não contém nome, BI, telefone nem morada.

- **Segurança clínica:** a IA não consegue baixar a prioridade de triagem abaixo do piso; as alergias são detectadas mesmo com a IA em baixo; os valores de pânico mantêm o exame crítico mesmo que a IA diga o contrário.
- **Regras:** classificação de sinais vitais por limiar, conflitos de alergia por classe sem falsos positivos (por exemplo, "ácido fólico" não é confundido com "ácido acetilsalicílico"), valores de pânico com vírgula decimal, separadores de milhares e conversão de unidades.
- **Fiabilidade:** passagem para o modelo de reserva em caso de sobrecarga e de timeout, pausa e regresso de modelos, erro claro quando todos estão no limite, repetição da análise de exames.
- **Acesso:** um médico não acede às conversas de outro; o enfermeiro não vê a análise de exames.

Foram também feitos testes ponta a ponta com o servidor real e a API Gemini, que confirmaram o funcionamento das seis funcionalidades com respostas clinicamente coerentes (ver os exemplos nas secções 3.1, 3.4 e 3.6) e a ordenação da fila de espera por prioridade (Vermelho → Laranja → Verde).

8. Limitações e trabalho futuro

Limitação	Mitigação actual / próximo passo
As regras clínicas (limiares de sinais vitais, classes de alergia, valores de pânico) são aproximações conservadoras.	Devem ser revistas e validadas pela direcção clínica antes do uso em produção; estão concentradas num único ficheiro para facilitar essa revisão.
Os modelos de linguagem podem errar ou inventar informação.	Saída estruturada, regras de segurança, instruções para não inventar dados e confirmação obrigatória pelo profissional. Próximo passo: medir a concordância entre sugestões e decisões finais.
Dependência de um fornecedor externo, com latência variável.	Modelos de reserva, pausa automática e degradação graciosa. Próximo passo: plano pago e, a prazo, avaliar um modelo alojado localmente.
A detecção de valores críticos depende de o resultado ser escrito em texto com nomes reconhecíveis.	A IA complementa as regras. Próximo passo: integração estruturada com o sistema do laboratório.
O sistema não é um dispositivo médico certificado.	Todas as funcionalidades são apresentadas como apoio à decisão; a decisão e a responsabilidade são do profissional.

Anexo — Configuração

A IA é configurada no ficheiro `leevida-backend/.env`. Sem chave, as funcionalidades de IA ficam desactivadas e a aplicação funciona normalmente com as regras locais.

```
GEMINI_API_KEY=<chave obtida em aistudio.google.com/apikey>
GEMINI_MODEL="gemini-3.5-flash"
GEMINI_FALLBACK_MODELS="gemini-3.8-flash,gemini-3.5-flash-lite"
CLINIC_TIMEZONE="Africa/Luanda"
```

Endpoint	Perfil	Função
`GET /ai/status`	Médico, enfermeiro, admin	Indica se a IA está activa
`POST /ai/triage-priority`	Enfermeiro, admin	Sugestão de prioridade de triagem
`GET /ai/patients/:id/summary`	Médico	Resumo pré-consulta
`POST /ai/prescription-assistant`	Médico	Mensagem no assistente
`GET|DELETE /ai/conversations`	Médico	Histórico de conversas
`POST /ai/prescriptions/:id/check`	Médico	Verificação da receita
`POST /ai/exams/:id/interpret`	Médico	Interpretação de exame
`POST /ai/icd10`	Médico	Sugestão de CID-10